

COMBINANDO TÉCNICAS CONTEXTUAIS PARA MELHORAR SISTEMAS DE RECOMENDAÇÃO SENSÍVEIS AO CONTEXTO

Igor André Pegoraro Santana (PIBIC/CNPq), Marcos Aurelio Domingues
(Orientador), e-mail: ra83154@uem.br.

Universidade Estadual de Maringá / Centro de Tecnologia/Maringá, PR.

Área e subárea do conhecimento conforme tabela do [CNPq/CAPES](#)

Palavras-chave: sistemas de recomendação, *Combined Reduction*, *DaVI*.

Resumo

Este projeto implementou um algoritmo criado a partir da junção dos algoritmos de recomendação sensíveis ao contexto *Combined Reduction* e *DaVI*, visando melhorar os resultados obtidos nos mesmos. Estes algoritmos utilizam informações contextuais referentes a uma avaliação feita por um usuário a um item, com o objetivo de realizar predições melhores em relação a algoritmos de recomendação que não utilizam estas informações. O projeto foi desenvolvido utilizando tecnologia *Java*, fazendo uso do *framework* CARSKit para o desenvolvimento do algoritmo.

Introdução

Um sistema de recomendação utiliza-se de informações de itens no qual um usuário avaliou em uma aplicação para fazer predições relativas ao mesmo. Estas recomendações podem condizer com diversas áreas de utilização, como em uma biblioteca digital, que livros podem ser recomendados para seus usuários, ou em uma aplicação multimídia onde artistas e músicas podem ser recomendados. Como recomendações geralmente são personalizadas, diferentes usuários ou grupos de usuários podem receber sugestões diversas (ADOMAVICIUS et al., 2011).

No entanto, em um sistema de recomendação sensível ao contexto, informações contextuais também são utilizadas para auxiliar na predição, como por exemplo o horário no qual o item foi acessado, se o usuário estava acompanhado por alguém, entre outras. Conforme (ADOMAVICIUS; TUZHILIN, 2005), “a predição exata das preferências do consumidor depende, sem dúvida, do grau em que incorporamos a informação contextual relevante no método de recomendação”.

Estes algoritmos sensíveis ao contexto, como definidos anteriormente, assumem três possíveis vertentes, como visto em (ADOMAVICIUS et al., 2011), que são as seguintes:

- **Pré-filtragem Contextual:** Neste método, as informações contextuais são utilizadas para selecionar um grupo relevante de dados para então aplicar um algoritmo de recomendação tradicional neste grupo de dados;
- **Pós-filtragem Contextual:** As predições são obtidas utilizando algum algoritmo de recomendação e então filtradas ou ajustadas de acordo com algum método contextual;
- **Modelagem Contextual:** Para este método, as informações contextuais são incorporadas na técnica de modelagem do algoritmo para poder fazer recomendações.

Seguindo a vertente da modelagem contextual, (DOMINGUES; JORGE; SOARES, 2012) apresenta o algoritmo *DaVI*, que consiste em utilizar as informações contextuais como novos pares de usuário-item, tendo como seu principal benefício a capacidade de utilizar esta abordagem com algoritmos que não são sensíveis ao contexto, visando gerar recomendações melhores. O algoritmo utilizado neste projeto, chamado *DaVI-ALL*, estende o algoritmo *DaVI* permitindo a utilização de todas as dimensões existentes (valores que um determinado contexto pode assumir) para criar pares de usuário-item e, então, utilizar estes dados para fazer a recomendação.

O algoritmo *CombinedReduction*, utilizado neste projeto, faz parte do grupo de algoritmos de pré-filtragem contextual. Ele reduz o problema de recomendações multidimensionais para o espaço de recomendação bidimensional *Usuario×Item*. Isto ocorre pois o algoritmo seleciona o conjunto de dados das dimensões que obtiveram um resultado melhor que o conjunto de dados completo, e os utiliza para fazer a recomendação final.

Materiais e métodos

Foi utilizada a linguagem de programação *Java* para o desenvolvimento do projeto, em conjunto com o *framework CARSKit*, que é uma extensão do framework Librec porém com algoritmos de recomendação sensíveis ao contexto que permite o pesquisador adicionar novos algoritmos de recomendação junto com os demais algoritmos que já foram implementados pelo mesmo.

Resultados e Discussão

Para realizar os experimentos, foi utilizada uma coleção de filmes chamada DePaulMovie, que contém notas que usuários deram a filmes que foram assistidos. Esta base de dados contém informações relativas a localização (onde o usuário assistiu o filme, como por exemplo casa ou cinema) em que o filme foi assistido, tempo (final de semana ou durante a

semana) e companhia (assistiu com a família, parceiro ou sozinho). Esta coleção possui 97 usuários, 79 filmes avaliados e 5035 entradas (visualizações de filmes), onde a média de todas as notas dadas por usuários a filmes é de 3.29, em uma escala de 1 a 5.

A avaliação de desempenho dos algoritmos foi feita utilizando o modelo de validação cruzada de 10 partições, que consiste em dividir o conjunto de dados em 10 subconjuntos de mesmo tamanho e selecionar um desses conjuntos para teste e os demais conjuntos para treinar o modelo. Este processo é repetido 10 vezes, alternando o conjunto de teste entre os demais conjuntos em cada repetição. Junto com a validação cruzada, foram selecionadas as métricas F1, *Precision*, *Recall* e MAP, sendo que todas foram calculadas para 5 e 10 itens recomendados.

Foi utilizado durante os experimentos o algoritmo de filtragem colaborativa ItemKNN como base de comparação para os resultados obtidos nos algoritmos implementados, a fim de analisar se houve melhora no desempenho dos algoritmos sensíveis ao contexto. Os resultados obtidos estão na Tabela 1.

Tabela 1 - Resultados obtidos pelos algoritmos

	Precision		Recall		F1		MAP	
	5	10	5	10	5	10	5	10
ItemKNN	0,04432	0,01950	0,12619	0,23449	0,06588	0,07229	0,05876	0,07578
CombinedReduction	0,04806	0,04409	0,12664	0,23287	0,06651	0,07188	0,05863	0,07537
DaVI-CombinedReduction	0,05220	0,04592	0,14322	0,24665	0,07312	0,07508	0,06207	0,07873

Podemos perceber que houve ganho de desempenho do algoritmo *DaVI-CombinedReduction* com relação aos demais algoritmos. Em geral, o ganho médio foi maior com relação às métricas que utilizavam 5 itens ao invés de 10 itens. O menor ganho com 5 itens com relação ao *CombinedReduction* foi na métrica MAP, com um ganho de 5,87%, sendo que o maior ganho obtido foi de 13,1% na métrica *Recall*. Com 10 itens sendo recomendados, a métrica *Precision* teve um ganho de 4,15%, sendo então este o menor ganho dentre todas as outras, porém teve seu maior ganho na métrica *Recall*, com 5,9% de melhora.

Por fim, o melhor ganho obtido na métrica F1 com o *DaVI-CombinedReduction* foi de 11% com relação à base de comparação (algoritmo *ItemKNN*) e 9,9% com relação ao *CombinedReduction*. Isto mostra que utilizando esta base de dados, os resultados obtidos são positivos e as recomendações obtidas são melhores que as recomendações feitas pelos demais algoritmos.

Os resultados obtidos sugerem que a utilização de sistemas de recomendação que utilizam as informações contextuais como novos pares de usuários e itens, junto com algoritmos de recomendação de pré-filtragem, são capazes de produzir recomendações melhores do que o mesmo sistema de recomendação sozinho.

Conclusões

O projeto foi desenvolvido de acordo com o proposto e atendeu os objetivos que foram definidos inicialmente, obtendo resultados positivos de acordo com a hipótese apresentada. Uma das limitações encontradas durante o desenvolvimento foi a adaptação de partes do algoritmo para o padrão imposto pelo *framework*, visto que algumas funcionalidades necessárias não estavam implementadas.

Este trabalho contribuiu com o desenvolvimento de algoritmos para o *framework* CARSKit, aumentando o leque de algoritmos que podem ser utilizados para fazer recomendações sensíveis ao contexto.

Agradecimentos

Agradeço ao programa PIBIC/CNPq/FA/UEM pelo apoio financeiro e ao prof. Marcos Aurelio Domingues pela orientação durante o projeto.

Referências

ADOMAVICIUS, G.; TUZHILIN, A. **Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions**. IEEE TRANSACTIONS ON KNOWLEDGE AND DATA ENGINEERING, v. 17, n. 6, 2005.

ADOMAVICIUS, G. et al. **Recommender systems handbook**. In: Springer, 2011. v. 1, cap. Context-Aware Recommender Systems, p. 191–226.

DOMINGUES, M. A.; JORGE, A. M.; SOARES, C. **Dimensions as virtual items: Improving the predictive ability of top-n recommender systems**. Information Processing and Management, 2012.

ZHENG, Y. and MOBASHER, B. and BURKE, R. **"CARSKit: A Java-Based Context-aware Recommendation Engine"**. Proceedings of the 15th IEEE International Conference on Data Mining Workshops, 2015, IEEE.